## Decameron-FR

Vérités terrain pour la reconnaissance automatique d'écriture à partir d'un manuscrit français du Decameron (XVe siècle)

Sébastien Biay, Jean-Victor Boby, Zoé Cappe, Kristina Konstantinova 20 janvier 2022

# 1 Présentation du projet

## 1.1 Un projet de sources numériques sur Github/eScriptorium

Le projet **Decameron-FR** est un travail collectif autour des enjeux de l'*Handwritten Text Recognition* (HTR) basé sur l'utilisation du Git et Github pour la mise en commun du travail produit par chacun des membres du groupe, et la plateforme eScriptorium pour l'entraînement de modèles de reconnaissance automatique des écritures manuscrites.

L'intérêt de l'utilisation de Git et de Github dans ce projet de groupe était de pouvoir travailler à distance sur un dépôt commun, conserver un historique des modifications qui y ont été apportées, échanger sur les différents problèmes à résoudre, et vérifier les apports de chacun afin de pouvoir mieux les partager.

La plateforme eScriptorium a l'avantage d'être un projet *open source*, en ligne, et permet de travailler aisément à plusieurs sur un même projet.

Afin de tester un modèle de reconnaissance automatique des écritures manuscrites, nous avons choisi de travailler sur un manuscrit du  $XV^e$  siècle. Un travail préalable a donc été nécessaire, afin d'établir des normes concernant la transcription des caractères particuliers et de la ponctuation, et une procédure à suivre pour la segmentation du texte. Cela a imposé un choix parmi des modèles à tester, qui s'est finalement porté sur deux d'entre eux : le modèle CREMMA-Médiéval 1.0.0 et le modèle fine Tun Eneide.

### 1.2 Choix de la source et des modèles

#### 1.2.1 Le manuscrit Paris, Arsenal, réserve 5070

Plusieurs membres du groupe ayant eu l'occasion de travailler sur un texte commun en première année de master TNAH – la traduction française du *Decameron* de Boccace par Laurent de Premierfait –, nous avons choisi de pousser ce sujet plus loin. Le manuscrit que nous avions transcrit étant conservé à la Biblioteca Apostolica Vaticana (Pal. lat. 1989), dont les images diffusées en ligne ne sont pas libres de droits, nous nous sommes reportés sur le manuscrit Paris, Bibliothèque de l'Arsenal, Ms-5070 réserve, accessible sur Gallica <sup>1</sup> et dont le colophon précise qu'il a été copié sur le fameux manuscrit du Vatican <sup>2</sup>.

Le ms. 5070 de l'Arsenal date du deuxième quart du  $xv^e$  siècle. Son écriture se rattache à la catégorie de la littera cursiva selon la classification de Lieftinck-Gumbert-Derolez, catégorie décrite ainsi par D. Stutzmann :

La *littera cursiva* se caractérise par un a à simple ove, des f et s longs filant sur la ligne, et des lettres à hastes avec des boucles. Elle est donc à l'opposé de la *littera textualis*<sup>3</sup>.

Son écriture, très régulière, est le fait d'une seule main. Le colophon révèle l'identité du copiste :

Explicit la table du transcripvain Guillebert de Mets, hoste de l'Escu de France a Gramont<sup>4</sup>.

Né vers 1390 à Grammont (Flandres), Guillebert de Mets exerça l'activité de copiste pour les ducs de Bourgogne à Paris <sup>5</sup>.

<sup>1.</sup> Gallica, Paris, Bibliothèque de l'Arsenal, ms. 5070, URL: https://gallica.bnf.fr/ark:/12148/btv1b7100018t (visité le 15/01/2022); BNF Archives et Manuscrits, Ms-5070. Boccace. Decameron, Traduit Par Laurent de Premierfait. 1414, URL: https://archivesetmanuscrits.bnf.fr/ark:/12148/cc87590n (visité le 07/01/2022).

<sup>2.</sup> Jonas-IRHT, Paris, Bibliothèque de l'Arsenal, 5070, Jonas, Répertoire des textes et des manuscrits médiévaux d'oc et d'oïl, 19 sept. 2012, URL: https://jonas.irht.cnrs.fr/manuscrit/43038 (visité le 07/01/2022).

<sup>3.</sup> Dominique Stutzmann, Les Écritures Gothiques Livresques: Classification de Lieftinck-Gumbert-Derolez, Paléographie médiévale, 7 janv. 2022, URL: https://ephepaleographie.wordpress.com/qu%e2%80%99est-ce-que-la-paleographie/les-ecritures-gothiques-livresques-classification-de-lieftinck-gumbert-derolez/ (visité le 07/01/2022).

<sup>4.</sup> Jonas-IRHT, Paris, Bibliothèque de l'Arsenal, 5070...

<sup>5.</sup> Id., Guillebert de Mets, Jonas, Répertoire des textes et des manuscrits médiévaux d'oc et d'oïl, URL: https://jonas.irht.cnrs.fr/consulter/intervenant/detail\_intervenant.php?intervenant=2908 (visité le 08/01/2022).

# 1.2.2 Modèles HTR pour les manuscrits littéraires médiévaux et spécificités de leurs corpus d'entraînement

**Cremma Médiéval 1.0.0 Bicerin** Le premier modèle HTR que nous avons choisi est l'un des deux modèles entraînés dans le cadre du projet Consortium Reconnaissance d'Écriture Manuscrite des Matériaux Anciens (CREMMA) sur les manuscrits médiévaux du XII<sup>e</sup> au XIV<sup>e</sup> siècle : 1.0.0 Bicerin <sup>6</sup>.

Modele fineTunEneide Le second modèle que nous avons testé est une personnalisation du modèle Bicerin 1.0.0 à partir de l'écriture du manuscrit Philadelphie, University of Pennsylvania, Rare Book and Manuscript Library, Codex 909, réalisée par Lucien Dugaz dans le cadre d'une recherche post-doctorale au sein du Centre Jean Mabillon (EA 3624). Écrit en France dans la seconde moitié du XV<sup>e</sup> siècle, ce manuscrit est plus proche d'Arsenal 5070 par sa chronologie, et son écriture est de type gothique bâtarde <sup>7</sup>.

#### 1.2.3 Ontologie de segmentation des zones : Segmonto

Pour réaliser la segmentation en zones des pages de notre manuscrit, nous avons suivi les propositions de typage des zones formulées dans les Guidelines du projet SegmOnto, dont le vocabulaire contrôlé couvrait largement nos besoins  $^8$ .

## 2 Mise en oeuvre

Les sources choisies et le sujet défini, la planification du projet a constitué notre première étape, afin d'élaborer le plan d'exécution. Cette phase essentielle a permis d'identifier les tâches successives à réaliser, leur ordre, leur répartition et leurs délais respectifs. Elle a également servi à s'accorder sur le fonctionnement de l'équipe, les responsabilités de chacun et les méthodes de conduite et de suivi du projet.

## 2.1 Organisation fonctionnelle et aspects techniques

#### 2.1.1 Git et GitHub:

Un dépôt distant GitHub <sup>9</sup> est créé et partagé pour la gestion du projet. Les membres de l'équipe traitent chacune des tâches qui leur sont assignées au sein d'une branche dédiée dans leurs dépôts locaux, clonés avec Git <sup>10</sup> à l'aide des commandes du terminal comme indiqué dans le schéma ci-dessous :

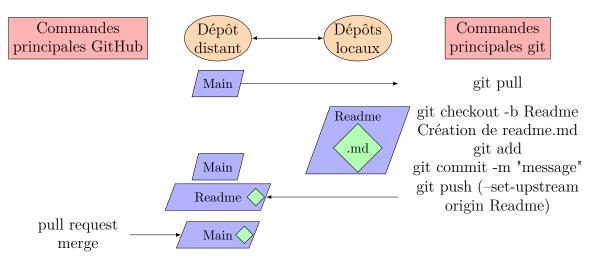


FIGURE 1 – Processus de création d'un readme.md pour le dépôt

<sup>6.</sup> Ariane Pinche, CREMMA Medieval, an Old French Dataset for HTR and Segmentation, version 1.0.1 Bicerin (DOI), août 2021, DOI: 10.5281/zenodo.5235186.

<sup>7.</sup> Lucien Dugaz, Édition Critique Numérique de La Première Énéide Française: à La Gloire de Louis XII et de La Translatio Studii, projet de recherche post-doctorale, Paris, Labex Hastec-Centre Jean-Mabillon, 2021, URL: https://labexhastec.ephe.psl.eu/wp-content/uploads/hastec-projet-de-recherche-lucien-dugaz-2021-2022.pdf (visité le 13/01/2022); Penn Libraries, Medieval & Renaissance Manuscripts Collection: Ms. Codex 909 - Virgil - [Le Livre Des Eneydes], Penn in Hand: Selected Manuscripts, URL: http://dla.library.upenn.edu/dla/medren/pageturn.html?id=MEDREN\_9940098043503681 (visité le 13/01/2022).

<sup>8.</sup> Jean-Baptiste Camps, SegmOnto Guidelines, SegmOnto, 10 déc. 2021, URL: https://github.com/SegmOnto/Guidelines (visité le 07/01/2022).

<sup>9.</sup> Voir TNAH-2021-DecameronFR à https://github.com/PSL-Chartes-HTR-Students.

<sup>10.</sup> Git version 2.25.1.

Lorsqu'une tâche est achevée, les mises à jour sont envoyées sur le dépôt distant afin que l'équipe les valide et fusionne les modifications vers la branche principale (main), le cas échéant. Chaque thème important fait l'objet de développements dans une branche distincte  $^{11}$ , notamment pour l'établissement des normes et les transcriptions individuelles.

La fonctionnalité des *issues* de GitHub est quant à elle dédiée aux échanges de l'équipe, également par sujets. Autant que possible, un lien est établi entre les branches, la documentation qu'elles contiennent et les *issues*. Ces dernières doivent être rédigées de manière claire et illustrées, en particulier sur les points de discussion relatifs aux transcriptions et à leurs normes.

#### 2.1.2 eScriptorium

Un projet commun a été créé sur eScriptorium, sur lequel les images qui avaient été sélectionnées pour la transcription ont été importées. L'import par le manifeste IIIF a été préféré à un PDF ou des fichiers locaux, afin d'obtenir la meilleure qualité d'image possible.

Les pages ont d'abord été segmentées automatiquement, puis cette segmentation a été corrigée manuellement, notamment pour la séparation des zones de texte et de lignes (colonnes, titre courant, notes en marge, lettrines), la suppression des zones et lignes inutiles (texte des pages suivantes apparaissant sur le côté des images) et pour la numérotation des lignes (colonnes et titre courant). Les zones ont pu être nommées selon les propositions de SegmOnto, après leur ajout dans l'onglet «Description».

Une fois la segmentation terminée, les deux modèles (Bicerin 1.0.0 et fineTunEneide) ont pu être testés. La transcription a ensuite été faite dans l'onglet manual des modèles, et la transcription multi-ligne a été utilisée : en plus d'avoir l'avantage de mettre en surbrillance la ligne qui est en cours de transcription, elle permet d'utiliser aisément le clavier virtuel qui a été importé depuis le dépôt commun. Les transcriptions ont ensuite été exportées au format XML (selon le standard ALTO) depuis eScriptorium, et déposées par chacun dans le dépôt grâce à Git.

## 2.2 Préparation et réalisation de la transcription

#### 2.2.1 Etablissement des normes de transcription

Les normes de transcription que nous avons adoptées et qui sont détaillées dans le fichier normes Transcription.md s'efforcent de suivre celles définies dans le cadre du projet CREMMA-Médiéval, elles mêmes inspirées de la graphemic transcription telle que conçue par D. Stutzmann <sup>12</sup>. Les fautes n'ont pas été corrigées ni les abréviations résolues. Nous avons occasionnellement fait appel aux caractères proposés par *The Medieval Unicode Font Initiative* (MUFI) <sup>13</sup>. Les choix d'encodage correspondant à chaque abréviation sont listés dans le fichier caracteres.html.

## 2.2.2 Le problème des i/j et u/v

L'application des principes de la transcription graphématique a rencontré quelque diffilcuté à propos des caractères i/j et u/v.

**Hétérogénéité du corpus CREMMA-Médiéval** Les vérités de terrain du projet CREMMA-Médiéval présentent une inégalité de traitement : i/j et u/v y sont parfois distingués selon leur valeur phonétique malgré l'absence de distinction graphique ; ils sont parfois distingués selon leur forme graphique indépendamment de leur valeur phonétique <sup>14</sup>.

La transcription graphématique : une définition difficile à saisir La définition de la graphemic transcription proposée dans l'article de D. Stutzman cité en référence par le projet CREMMA-Médiéval <sup>15</sup> ne nous a pas permis de lever cette difficulté de manière définitive. L'auteur écrit que la tradition philologique aurait déjà clarifié les problèmes de la graphemic transcription, citant les Conseils pour l'édition des textes médiévaux

<sup>11.</sup> Voir la liste des branches sur le dépôt.

<sup>12.</sup> Voir le fichier Lisez-moi du dépôt d'A. Pinche, CREMMA Medieval, an Old French Dataset for HTR and Segmentation...; D. Stutzmann, « Paléographie statistique pour décrire, identifier, dater... Normaliser pour coopérer et aller plus loin? », dans Kodikologie und Paläographie im digitalen Zeitalter 2 - Codicology and Palaeography in the Digital Age 2, dir. Franz Fischer, Christiane Fritze et Georg Vogeler, Norderstedt, 2011, t. 3, p. 247-277, URL: https://kups.ub.uni-koeln.de/4353/ (visité le 08/01/2022)

<sup>13.</sup> The Medieval Unicode Font Initiative, Medieval Unicode Font Initiative, 19 févr. 2016, URL: https://skaldic.org//m.php (visité le 17/01/2022).

<sup>14.</sup> Voir les exemples du document normesTranscription.md

<sup>15.</sup> Id., « Paléographie statistique pour décrire, identifier, dater..... », p. 251.

publiés par l'École des chartes <sup>16</sup>. Pourtant, cette publication prône essentiellement des normes de transcription de type interprétative pour les textes littéraires; les abréviations y sont restituées et les lettres i/j et u/v distinguées, en l'absence de doute selon leur valeur phonétique et non graphique <sup>17</sup>.

Choix : avantages et inconvénients Nous avons fait le choix de ne distinguer i/j et u/v ni selon leur valeur, ni selon leur forme. La limite de ce choix de ne pas distinguer i/j et u/v est certes de rendre impropre nos données à l'étude de l'apparition des lettres v et j dans les manuscrits médiévaux. Ce choix a en revanche pour avantage sa simplicité de conception, et reste en cohérence avec le système graphique du manuscrit dans la mesure où il ne l'affecte que sur les caractères initiaux : le scribe a employé les caractères j et v exclusivement et systématiquement en position initiale; nous les avons toujours transcrits i et u. Ce choix n'interprétant pas la valeur phonétique des caractères, il ménage ainsi la possibilité d'une évolution des normes.

#### 2.2.3 Utilisation de la plateforme eScriptorium

La mise en page très canonique (texte sur deux colonnes) et l'absence d'ajout au texte sur les pages que nous avons traitées ont rendu aisée l'étape de la segmentation des folios, bien que la prise en main de la plateforme eScriptorium ne se soit avérée quelque peu déroutante.

Segmentation La fonction dessiner une ligne étant par défaut activée, le moindre clic gauche pour sélectionner un objet s'est avéré périlleux! La segmentation automatique peine a distinguer clairement les deux colonnes de texte, à redécouper dans la plupart des cas. Autre problème, heureusement peu fréquent, les bouts de ligne de la page en regard, qui sont susceptibles d'apparaître en bordure de la photographie d'une page, ne sont pas d'une suppression évidente, et tenter de sélectionner ces lignes pour les supprimer conduit souvent à créer de nouvelles lignes, jusqu'à ce que l'on affiche la zone concernée à 800% de sa taille réelle pour sélectionner les embryons de lignes indésirables.

**Transcription** Les caractères générés par le modèle Bicerin ont permis de constater de très nombreuses confusions entre f et l, dont résulte la transcription de nombreux l en s. Ces confusions ont confirmé l'importance de la distinction des s longs et des s ronds que nous avions retenue parmi les normes de transcription du projet, par-delà l'argument de la stabilité des choix scribaux sur la longue durée, qui fonde a priori la distinction des allographes de s.

Notre texte étant particulièrement proche de celui de la Bibliothèque vaticane (composé dans une écriture plus livresque), la confrontation des manuscrits nous a permis de lever toutes les difficultés de lecture.

L'utilisation du clavier virtuel s'est avérée salutaire pour la saisie des caractères spéciaux définis dans notre table des caractères. En revanche, nous avons souvent été confronté à un bogue consistant en l'insertion du caractère sélectionné sur le clavier virtuel non pas à l'emplacement de la saisie en cours mais au début de la ligne. Ce problème survient lors de la saisie dans une ligne donnée d'un premier caractère au clavier virtuel, et non pour les caractères suivants. Ce premier caractère effacé, les suivants seront insérés comme il se doit à l'emplacement du curseur. Mais le problème se représentera dès la ligne suivante!

Autre facétie de la plateforme : la numérotation des lignes transcrites revenant entre deux sessions de travail à sa disposition initiale en dépit de sa modification manuelle. En effet, les titres courants ont parfois dû être placés plusieurs fois en position intiale, la machine s'obstinant à les placer après la numérotation des lignes de la première colonne.

## 3 Bilan

## 3.1 Réflexion sur l'organisation fonctionnelle et les aspects techniques

#### 3.1.1 Git et GitHub

D'un point de vue technique, après une période d'adaptation nécessaire à toute nouvelle pratique, les outils Git et GitHub se prêtent bien à la collaboration simultanée sur le projet. L'équipe semble maîtriser les processus de mise à jour et/ou de correction lorsque cela s'est avéré nécessaire (le facteur humain induisant inévitablement des erreurs ponctuelles). Sans doute, et surtout pour des projets plus conséquents, aurait-il fallu créer une branche dev de développement intermédiaire entre les branches et le main, pour limiter les risques de corrompre ce dernier.

Concernant la conduite du projet, sans surprise, il reste essentiel d'organiser des réunions de projet pour discuter de certains points, comme ceux qui sont trop complexes à expliciter exclusivement par écrit ou ceux

<sup>16.</sup> École nationale des chartes, Conseils pour l'édition des textes médiévaux, 3 fasc. Paris, 2001 (Orientations et méthodes).

<sup>17.</sup> Ibid., fasc. 1, p. 23 et suivantes, ainsi que 31 pour les abréviations.

qui n'ont pas vocation à être publiés. A elles seules, les fonctionnalités de discussion et de suivi permises via les issues ou les discussions GitHub ne sont pas suffisantes. A propos des issues, il aurait été préférable d'en ouvrir une nouvelle sur chaque question dès le départ, notamment s'agissant de la transcription des caractères : l'issue n° 11 a rassemblé les questionnements concernant trop de caractères différents. Par la suite, il est devenu difficile d'y retrouver une information. Enfin, GitHub ne semble pas permettre de déplacer un commentaire, d'une issue vers une autre (voire vers une nouvelle) qui lui correspondrait mieux, contrairement à de nombreux outils en ligne. Il semble seulement possible de faire des références.

#### 3.1.2 Evaluation de la plateforme eScriptorium

La plateforme eScriptorium est un outil qui permet de travailler sans difficulté en groupe, y compris simultanément; cela demande néanmoins une certaine coordination entre les membres de l'équipe, afin par exemple de ne pas modifier la segmentation achevée de folios déjà traités (et ainsi risquer d'écraser et de perdre les corrections préalablement effectuées).

L'utilisation de la plateforme peut être initialement assez complexe, mais après un peu de pratique, elle est facile à manipuler, pour la segmentation comme pour la transcription. Des problèmes mineurs demandent cependant des corrections supplémentaires : la segmentation automatique génère parfois des zones sur des régions sans inscriptions. Il s'est avéré parfois impossible de les supprimer entièrement à l'aide de l'outil dédié. Elles persistent alors à l'état de micro-zones de quelques pixels à peine visibles. Toutefois, elles peuvent être exclues des résultats extraits au format XML ALTO puisqu'elles ne bénéficient pas du typage SegmOnto établi pour le projet. D'autres complications peuvent être rencontrées après la segmentation au cours de la transcription (positionnement du curseur lors de l'insertion des caractères du clavier virtuel, numérotation du titre courant mentionnés ci-dessus). Il est parfois nécessaire de segmenter à nouveau une page pour corriger les lignes. Enfin des décalage de lettres dans la transcription imposent occasionnellement une relecture complète de la page.

Ces problèmes ont été résolus sans trop de difficultés sur notre petit nombre de pages (neuf en tout), mais sont beaucoup plus importants si l'on envisage de travailler sur un corpus beaucoup plus volumineux.

Il est aussi très intéressant de pouvoir choisir le modèle le plus adapté à l'écriture et la langue de son texte, tous les modèles déjà entraînés étant disponibles sur la plateforme, qui offre également la possibilité pouvoir entraîner son propre modèle <sup>18</sup>, à partir d'un modèle déjà existant ou non.

#### 3.1.3 Retour d'expérience

Outre l'apprentissage et l'approfondissement des compétences techniques nécessaires à l'utilisation de Git et de GitHub, ce projet a permis à l'équipe de se confronter aux enjeux d'un projet HTR, que ce soit du point de vue de la conduite de projet ou par rapport aux problématiques spécifiques à l'HTR.

Si les scores des modèles choisis atteignent généralement plus de 90%, nous ne pouvons pas chiffrer leurs performances sur le document que nous avons transcrit. Les résultats des transcriptions automatiques ne semblent pas véritablement satisfaisants. Nous aurions aimé tester les fonctionnalités d'entraı̂nement pour affiner des modèles existants (option  $Train^{19}$ ) ou créer un modèle dédié.

Les réflexions menées autour des règles SegmOnto et de transcription ont été riches. S'il est possible de décliner des normes toujours plus précises pour rester le plus proche des sources, nous avons observé que des choix pragmatiques et une limitation des caractères spéciaux étaient nécessaires afin d'assurer l'avancement du projet, toujours en essayant de trouver un équilibre entre une transcription au plus près du document et les besoins réels de eScriptorium pour entraîner les modèles. Les documentations, verités terrain et publications que nous avons consultées ne nous ont pas toujours conduits à des décisions évidentes. Ainsi nous avons dû arrêter nos arbitrages selon notre perception de la précision nécessaire et suffisante à apporter à la transcription de certains caractères, comme nous l'avons explicité plus haut. Il serait par conséquent intéressant de poursuivre cette réflexion dans la perspective de voir émerger des recommandations générales qui puissent être proposées pour des projets HTR futurs.

## Acronymes

CREMMA Consortium Reconnaissance d'Écriture Manuscrite des Matériaux Anciens. 2, 3

HTR Handwritten Text Recognition. 1, 2, 5

MUFI The Medieval Unicode Font Initiative. 3

<sup>18.</sup> La fonctionnalité doit être activée par les administrateurs

<sup>19.</sup> Alix Chagué, *Prendre en main eScriptorium*, LECTAUREP, URL: https://lectaurep.hypotheses.org/documentation/prendre-en-main-escriptorium (visité le 20/01/2022), au sujet de l'entraînement, voir le point 1.7.

## Références

## Projets et ressources

- CAMPS (Jean-Baptiste), SegmOnto Guidelines, SegmOnto, 10 déc. 2021, URL: https://github.com/SegmOnto/Guidelines (visité le 07/01/2022).
- CHAGUÉ (Alix), Prendre en main eScriptorium, LECTAUREP, URL: https://lectaurep.hypotheses.org/documentation/prendre-en-main-escriptorium (visité le 20/01/2022).
- PINCHE (Ariane), CREMMA Medieval, an Old French Dataset for HTR and Segmentation, version 1.0.1 Bicerin (DOI), août 2021, DOI: 10.5281/zenodo.5235186.
- The Medieval Unicode Font Initiative, Medieval Unicode Font Initiative, 19 févr. 2016, URL: https://skaldic.org//m.php (visité le 17/01/2022).

#### Notices

- BNF ARCHIVES ET MANUSCRITS, Ms-5070. Boccace. Decameron, Traduit Par Laurent de Premierfait. 1414, URL: https://archivesetmanuscrits.bnf.fr/ark:/12148/cc87590n (visité le 07/01/2022).
- Gallica, Paris, Bibliothèque de l'Arsenal, ms. 5070, URL: https://gallica.bnf.fr/ark:/12148/btv1b7100018t (visité le 15/01/2022).
- JONAS-IRHT, Paris, Bibliothèque de l'Arsenal, 5070, Jonas, Répertoire des textes et des manuscrits médiévaux d'oc et d'oïl, 19 sept. 2012, URL: https://jonas.irht.cnrs.fr/manuscrit/43038 (visité le 07/01/2022).
- Guillebert de Mets, Jonas, Répertoire des textes et des manuscrits médiévaux d'oc et d'oïl, URL: https://jonas.irht.cnrs.fr/consulter/intervenant/detail\_intervenant.php?intervenant=2908 (visité le 08/01/2022).
- PENN LIBRARIES, Medieval & Renaissance Manuscripts Collection: Ms. Codex 909 Virgil [Le Livre Des Eneydes], Penn in Hand: Selected Manuscripts, URL: http://dla.library.upenn.edu/dla/medren/pageturn.html?id=MEDREN\_9940098043503681 (visité le 13/01/2022).

## Études

- DUGAZ (Lucien), Édition Critique Numérique de La Première Énéide Française: à La Gloire de Louis XII et de La Translatio Studii, projet de recherche post-doctorale, Paris, Labex Hastec-Centre Jean-Mabillon, 2021, URL: https://labexhastec.ephe.psl.eu/wp-content/uploads/hastec-projet-de-recherche-lucien-dugaz-2021-2022.pdf (visité le 13/01/2022).
- ÉCOLE NATIONALE DES CHARTES, Conseils pour l'édition des textes médiévaux, 3 fasc. Paris, 2001 (Orientations et méthodes).
- STUTZMANN (Dominique), « Paléographie statistique pour décrire, identifier, dater... Normaliser pour coopérer et aller plus loin? », dans Kodikologie und Paläographie im digitalen Zeitalter 2 Codicology and Palaeography in the Digital Age 2, dir. Franz Fischer, Christiane Fritze et Georg Vogeler, Norderstedt, 2011, t. 3, p. 247-277, URL: https://kups.ub.uni-koeln.de/4353/ (visité le 08/01/2022).
- Les Écritures Gothiques Livresques: Classification de Lieftinck-Gumbert-Derolez, Paléographie médiévale, 7 janv. 2022, URL: https://ephepaleographie.wordpress.com/qu%e2%80%99est-ce-que-la-paleographie/les-ecritures-gothiques-livresques-classification-de-lieftinck-gumbert-derolez/(visité le 07/01/2022).